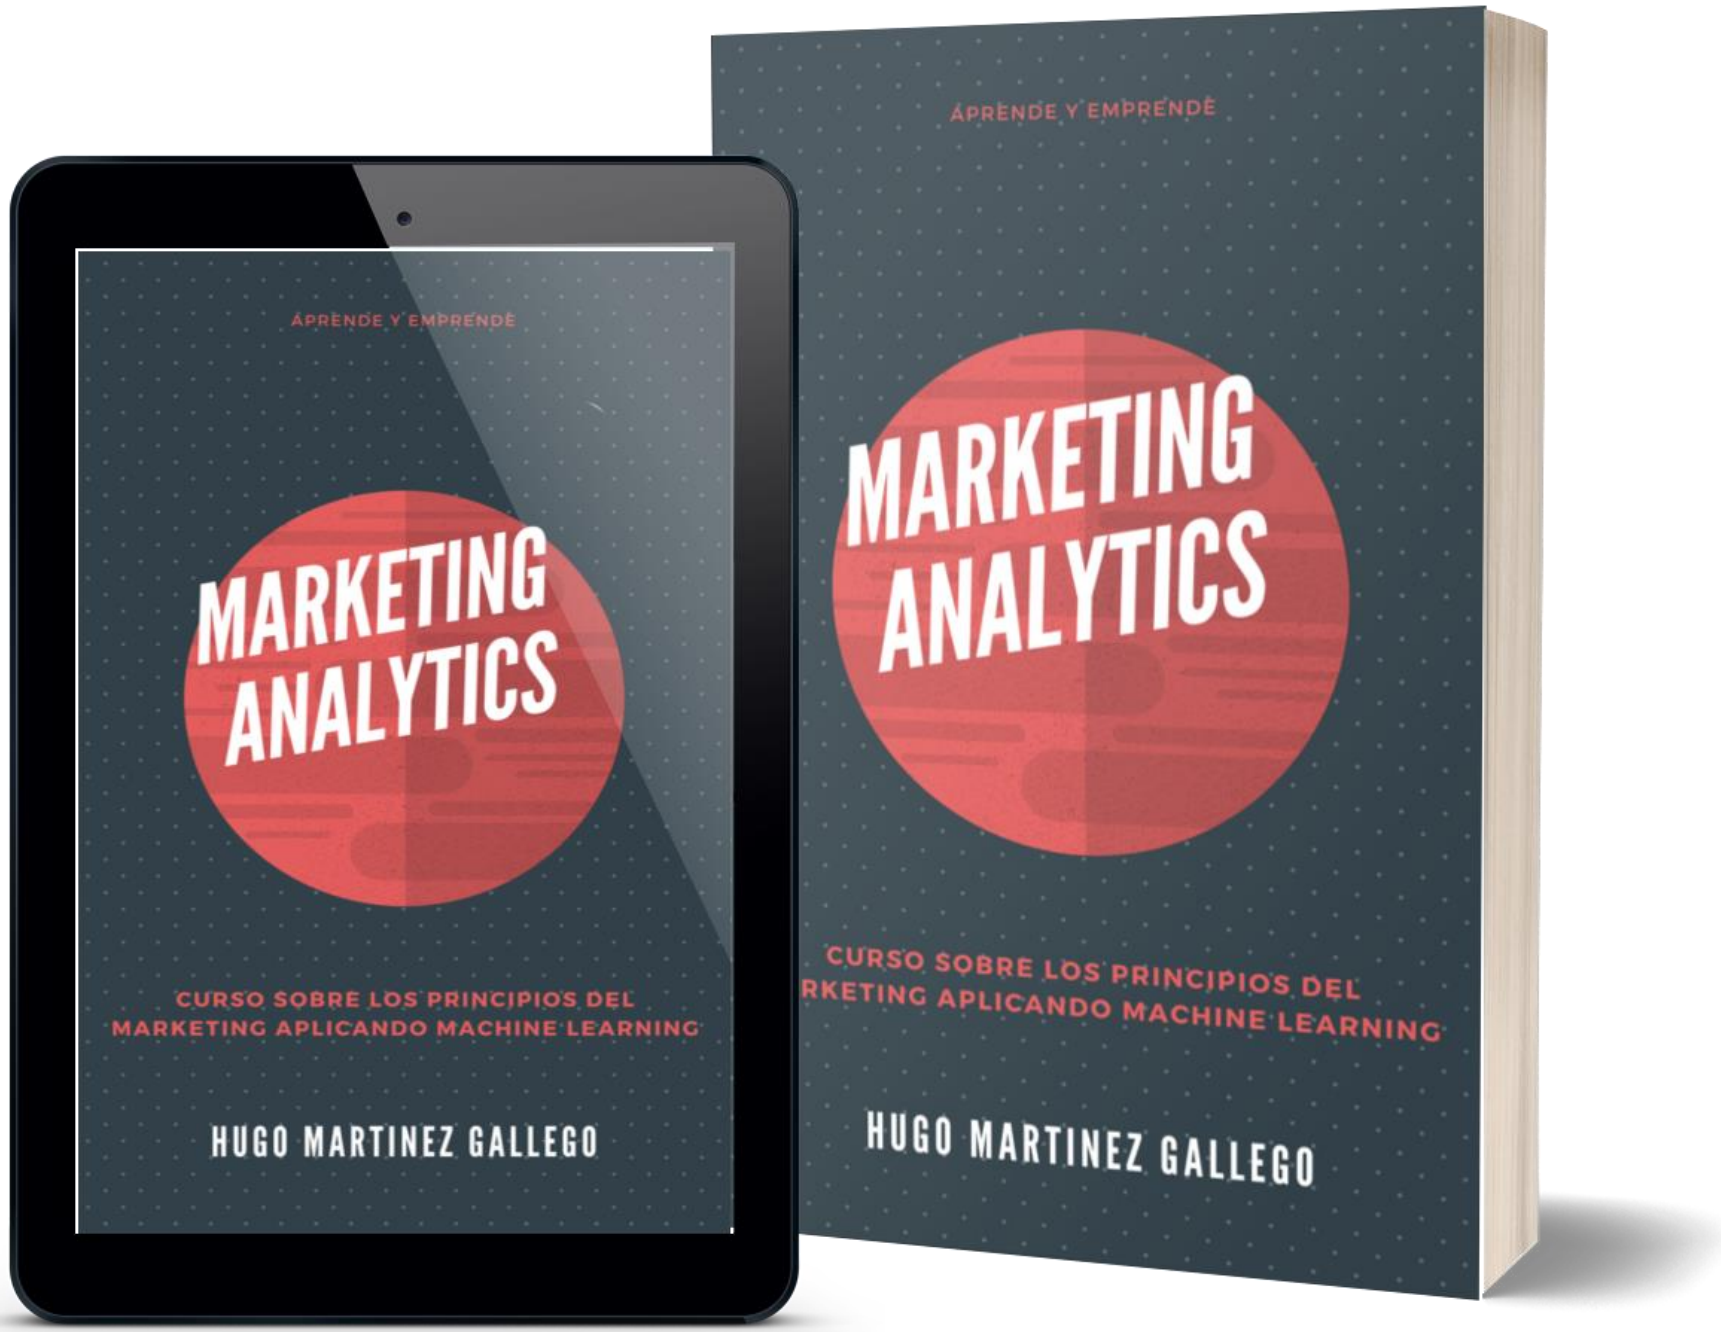

APRENDE Y EMPRENDE
MARKETING ANALYTICS
CURSO SOBRE LOS PRINCIPIOS DEL MARKETING APLICANDO MACHINE LEARNING
HUGO MARTINEZ GALLEGO
APRENDE Y EMPRENDE
MARKETING ANALYTICS
CURSO SOBRE LOS PRINCIPIOS DEL
RKETING APLICANDO MACHINE LEARNING
HUGO MARTINEZ GALLEGO

Hugo Alexander Martínez Gallego

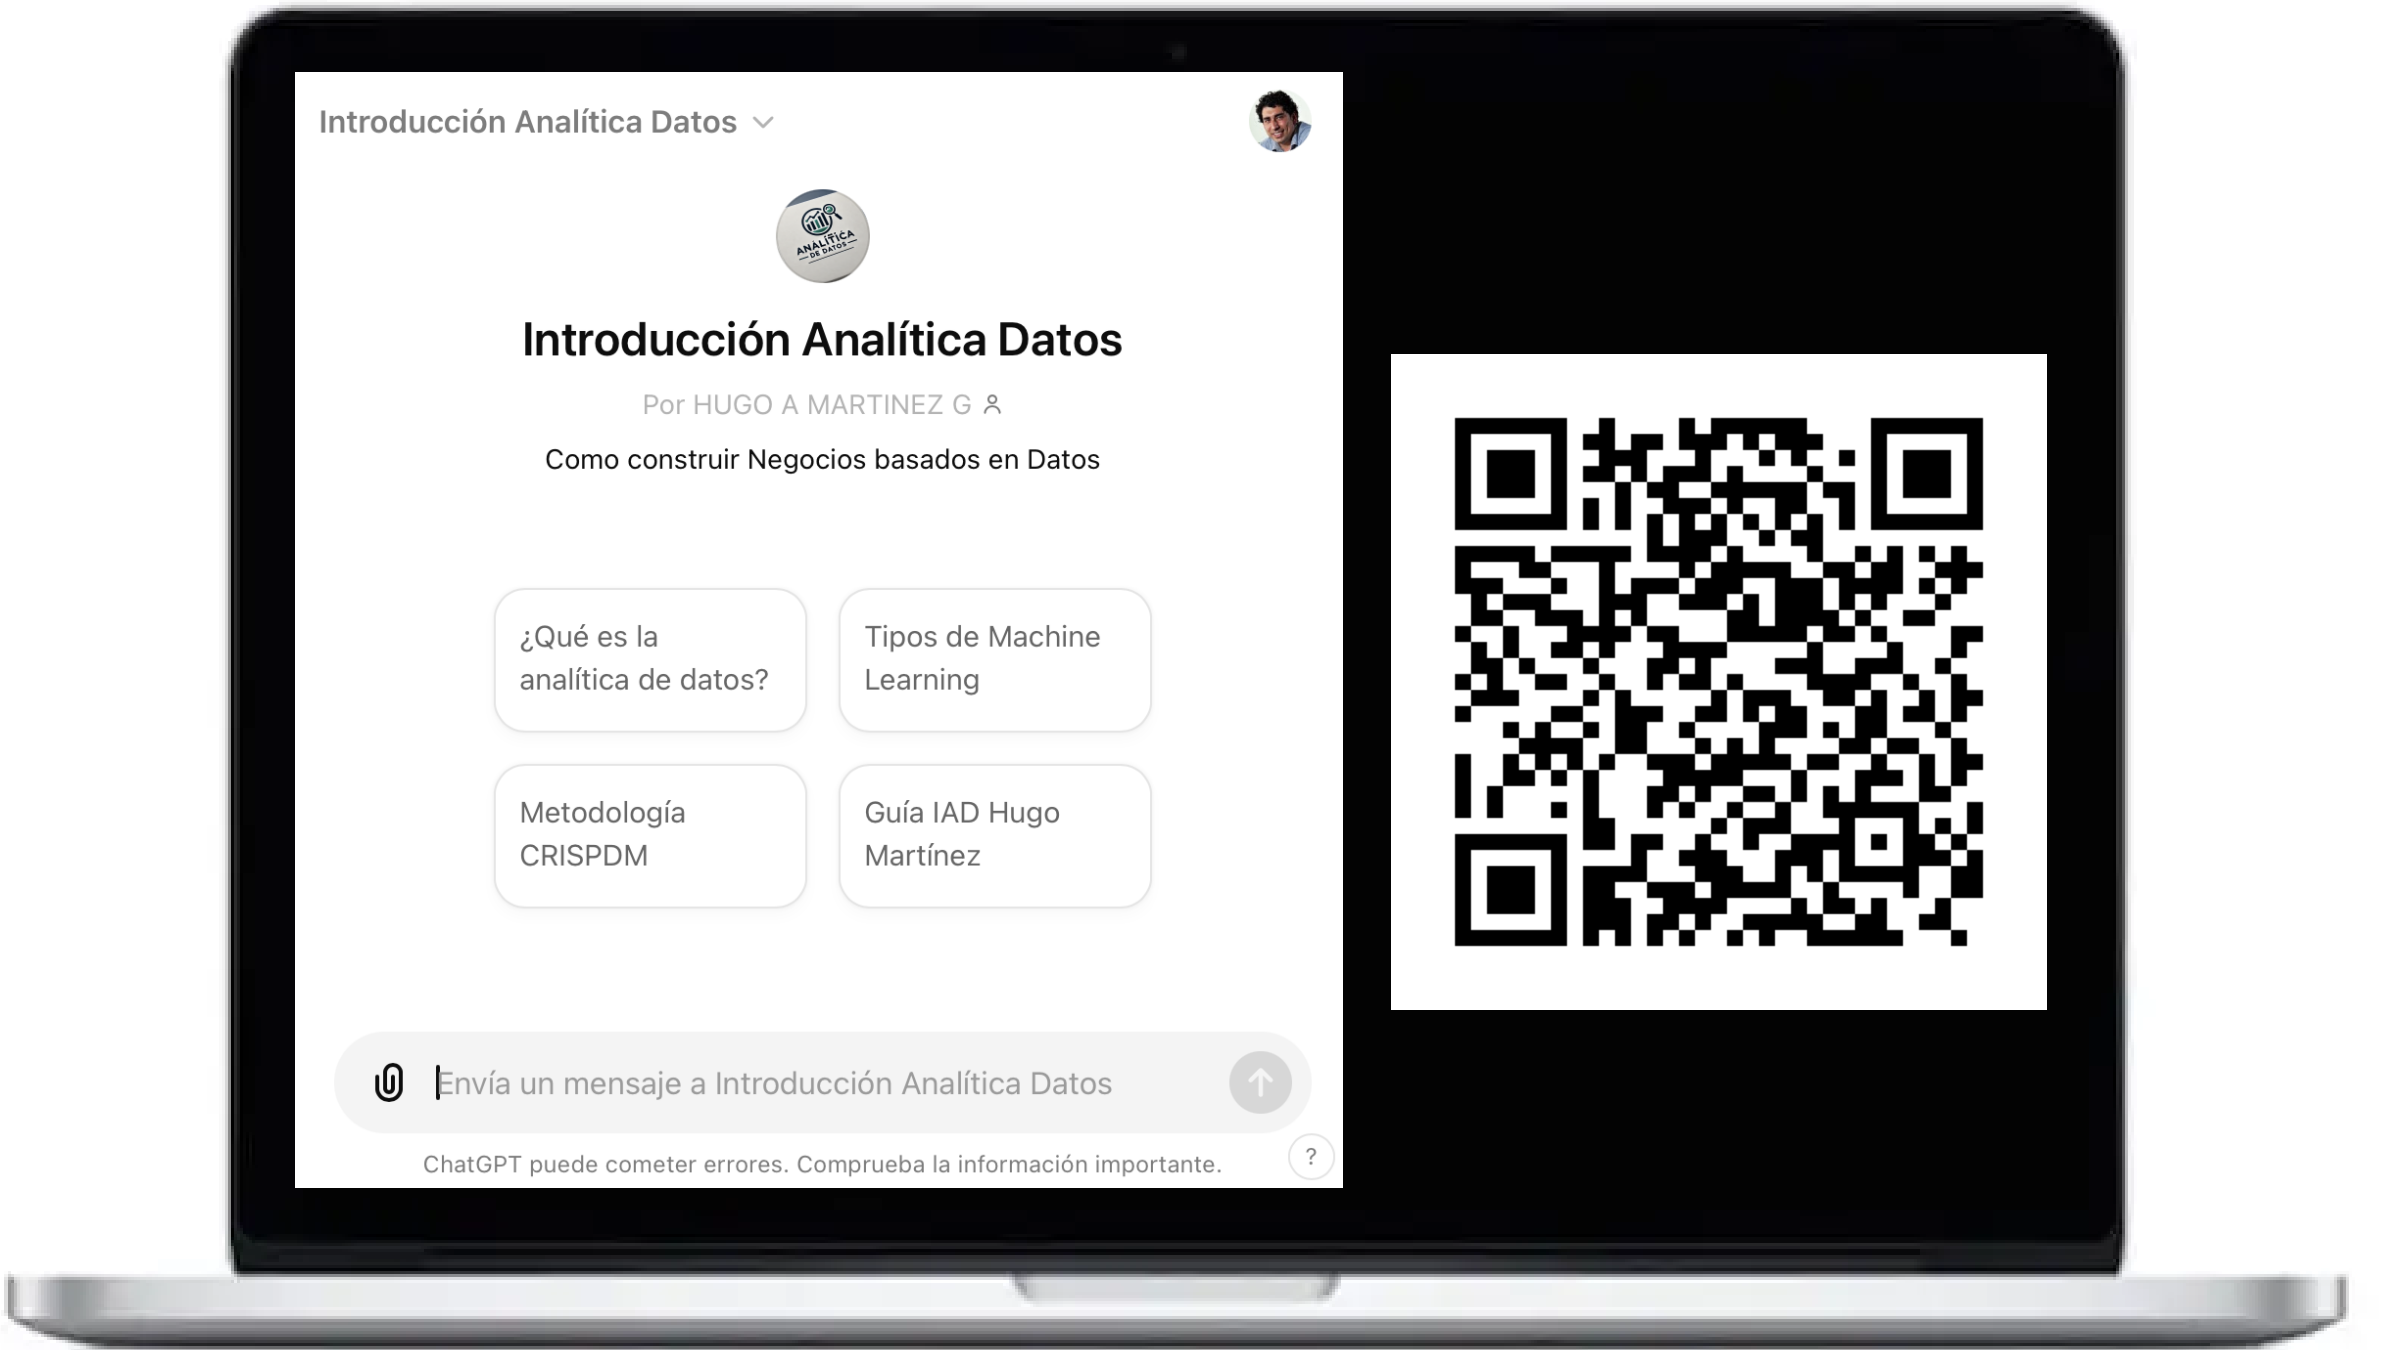


Matriz De Confusión

Matriz De Confusión

La matriz de confusión es una herramienta fundamental en Machine Learning para evaluar el rendimiento de un modelo de clasificación.

Ayuda a entender cuán bien está clasificando el modelo al mostrar el número de predicciones correctas e incorrectas que ha hecho, comparando las predicciones del modelo con los valores reales.


Introducción Analítica Datos
Introducción Analítica Datos
Por HUGO A MARTINEZ G
Como construir Negocios basados en Datos
¿Qué es la analítica de datos?
Tipos de Machine Learning
Metodología CRISPDM
Guía IAD Hugo Martínez
Envía un mensaje a Introducción Analítica Datos
ChatGPT puede cometer errores. Comprueba la información importante.

¿Cuál es la importancia de la matriz de confusión en la evaluación de modelos de clasificación en Machine Learning, y cómo puede aplicarse en el sector económico de televisión para mejorar la toma de decisiones?

Matriz De Confusión

	Predicción: Clase Positiva	Predicción: Clase Negativa
Valor Real: Positivo	Verdaderos Positivos (TP)	Falsos Negativos (FN)
Valor Real: Negativo	Falsos Positivos (FP)	Verdaderos Negativos (TN)

Verdaderos Positivos (TP): Casos en los que el modelo predijo correctamente la clase positiva.

Verdaderos Negativos (TN): Casos en los que el modelo predijo correctamente la clase negativa.

Falsos Positivos (FP): Casos en los que el modelo predijo la clase positiva, pero el valor real era negativo (también llamado "falsas alarmas").

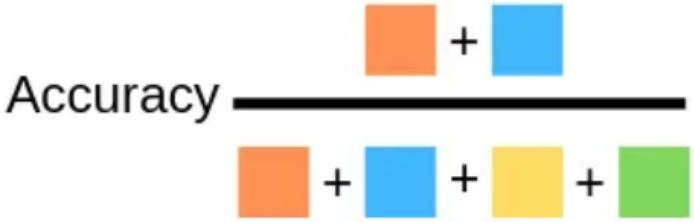
Falsos Negativos (FN): Casos en los que el modelo predijo la clase negativa, pero el valor real era positivo (también llamado "omisiones").

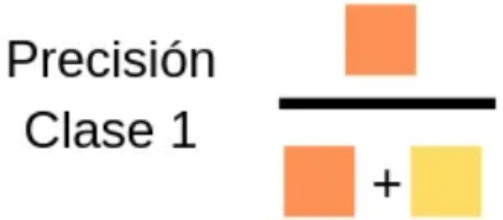
Matriz de Confusión

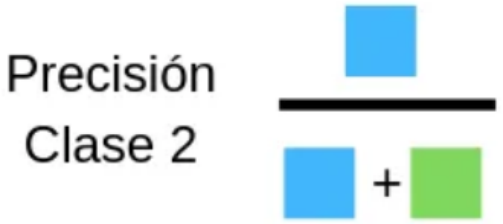


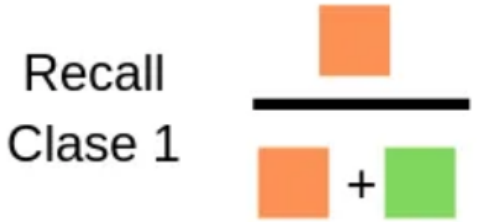
Matriz de Confusión

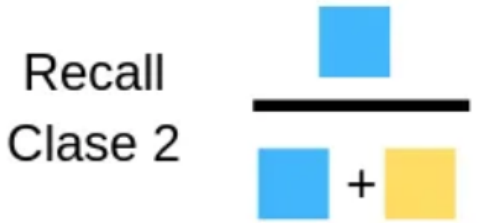








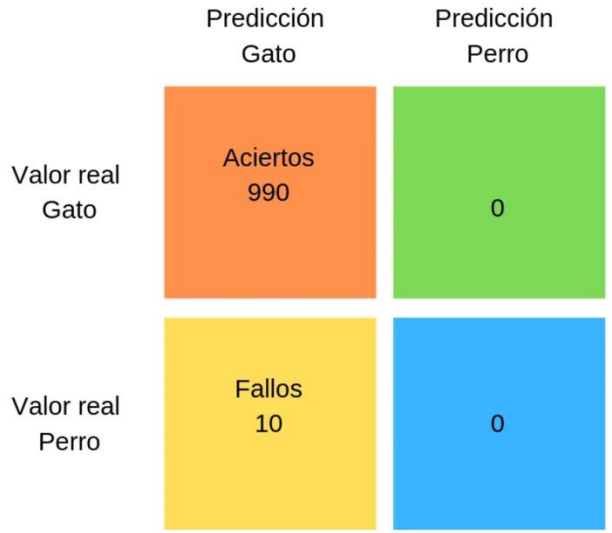




Veamos la Confusion matrix con el ejemplo de las predicciones de perro y gato.



Matriz de Confusión



$$\text{Accuracy} = \frac{990 + 0}{990 + 0 + 10 + 0}$$

$$\text{Precisión Clase 1} = \frac{990}{990 + 10}$$

$$\text{Recall Clase 1} = \frac{990}{990 + 0}$$

$$\text{Precisión Clase 2} = \frac{0}{0 + 0}$$

$$\text{Recall Clase 2} = \frac{0}{0 + 10}$$

La *Accuracy* del modelo es básicamente el número total de predicciones correctas dividido por el número total de predicciones. En este caso da 99% cuando no hemos logrado identificar ningún perro.

La Precisión de una clase define cuan confiable es un modelo en responder si un punto pertenece a esa clase. Para la clase gato será del 99% sin embargo para la de perro será 0%.

https://www.aprendemachinelearning.com/clasificacion-con-datos-desbalanceados/

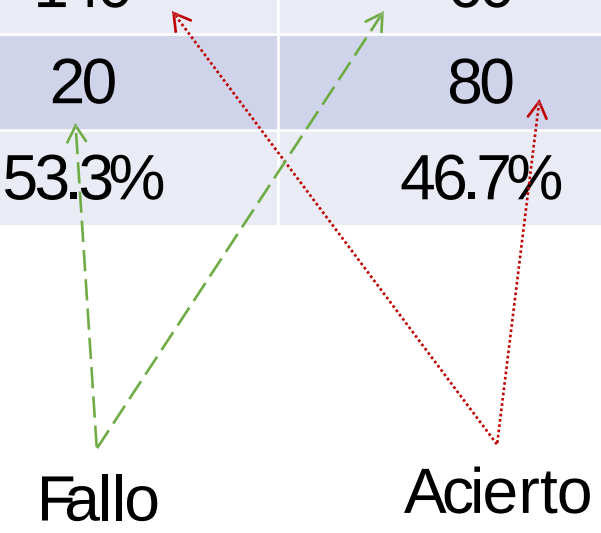
El Recall de una clase expresa cuan bien puede el modelo detectar a esa clase. Para gatos será de 1 y para perros 0.

El F1 Score de una clase es dada por la media armoníca de precisión y recall (2 x precisión x recall / (precisión+recall)) digamos que combina precisión y recall en una sola métrica. ¡En nuestro caso daría cero para perros!.

- Alta precision y alto recall: el modelo maneja perfectamente esa clase.
- Alta precision y bajo recall: el modelo no detecta la clase muy bien, pero cuando lo hace es altamente confiable.
- Baja precisión y alto recall: La clase detecta bien la clase pero también incluye muestras de otras clases.
- Baja precisión y bajo recall: El modelo no logra clasificar la clase correctamente.

Matriz de Confusión

Observado	Pronosticado	Pronosticado	Pronosticado
	Si	No	%correcto
Si	140	60	70%
No	20	80	80%
Global	53.3%	46.7%	73.3%



Matriz de Confusión

Observado	Pronosticado	Pronosticado	Pronosticado
	Si	No	%correcto
Si	140	60	70%
No	20	80	80%
Global	53.3%	46.7%	73.3%

Verdaderos positivos (TP)

Falso positivo (FP)

Falso negativo (FN)

Verdaderos negativos (TN)

Precisión y Exhaustividad

- **Precisión / Especificidad (precision):** Verdaderos positivos de todas las predicciones positivas

- **Exhaustividad / Sensibilidad (recall):** Verdaderos Positivos de todos los que son realmente positivos

Precisión y Exhaustividad

Observado	Pronosticado	Pronosticado	Pronosticado
	Si	No	%correcto
Si	140	60	70%
No	20	80	80%
Global	53.3%	46.7%	73.3%

Verdaderos positivos (TP)

Falso positivo (FP)

Falso negativo (FN)

Verdaderos negativos (TN)

$$Precision = \frac{TP}{TP + FP} = \frac{140}{140 + 20} = 87.5\%$$

$$Exhaustividad = \frac{TP}{TP + FN} = \frac{140}{140 + 60} = 70\%$$

F-Score

Media Armónica de precisión y exhaustividad

$$F-Score = 2 * \frac{precisión * exhaustividad}{precisión + exhaustividad} = 77.7\%$$

Overall Error Rate

Total de falsos positivos y falsos negativos dentro de las predicciones hechas.

$$OER = \frac{FP + FN}{FP + FN + TP + TN} = 26.7\%$$